

# Incertidumbre y conocimiento

- SI síntoma(P,dolor-de-muelas) ENTONCES enfermedad(P,caries)
  - ¿Expresa esta regla un conocimiento correcto?
  - Quizás sería mejor un conocimiento más exhaustivo:

```
SI sintoma(P,dolor-de-muelas)
  ENTONCES enfermedad(P,caries) 0
                enfermedad(P,sinusitis) 0
                enfermedad(P,muela-del-juicio) 0
                .....
```

- ¿Por qué a veces el conocimiento categórico no nos sirve?
  - Demasiado trabajo ser exhaustivo
  - Desconocimiento teórico
  - Desconocimiento práctico

# Incertidumbre y conocimiento

- Otra forma de expresar el conocimiento: grado de creencia
  - *Creemos*, basándonos en nuestras *percepciones*, que un paciente que tenga dolor de muelas, tiene caries con una probabilidad del 80 %
  - $P(Caries = true | Dolor = true) = 0,8$
  - La probabilidad expresa el *grado de creencia*, no el *grado de verdad*
  - Por tanto, la probabilidad puede cambiar a medida que se conocen nuevas *evidencias*
- La teoría de la probabilidad servirá como medio de representación de conocimiento incierto

# Variables aleatorias

- **Variables aleatorias:** una “parte” del mundo cuyo estado podemos desconocer
  - Ejemplo: la variable aleatoria *Caries* describe el hecho de que un paciente pueda o no tener caries
  - Nuestra descripción del mundo vendrá dada por un conjunto de variables aleatorias
- Una variable aleatoria puede tomar diferentes *valores* de su *dominio*
  - Los posibles valores de *Caries* son *true* y *false*
  - Notación: variables aleatorias en mayúsculas y sus valores en minúsculas
- Tipos de variables aleatorias:
  - Booleanas (notación: *caries* y  $\neg$ *caries* son equivalentes a  $Caries = true$  y  $Caries = false$ , respectivamente)
  - Discretas (incluyen a las booleanas)
  - Continuas
- En lo que sigue, nos centraremos en las variables discretas

# Proposiciones

- Usando las conectivas proposicionales y las variables aleatorias, podemos expresar *proposiciones*
- Ejemplos:
  - $\text{caries} \wedge \neg \text{dolor}$
  - $\text{Caries} = \text{true} \vee \text{Tiempo} = \text{nublado}$
  - $\text{Tirada1} = 5 \wedge (\text{Tirada2} = 4 \vee \text{Tirada2} = 5 \vee \text{Tirada2} = 6)$
- Asignaremos probabilidades a las proposiciones para expresar nuestro grado de creencia en las mismas

## Eventos atómicos

- Dado un conjunto de variables aleatorias que describen nuestro “mundo”, un evento atómico es un tipo particular de proposición:
  - Conjunción de proposiciones elementales, que expresan un valor concreto para todas y cada una de las variables
  - Ejemplo:  $\text{caries} \wedge \neg \text{dolor}$ , siempre que *Caries* y *Dolor* sean todas las variables aleatorias en nuestra descripción del mundo
- Características:
  - Mútuamente excluyentes
  - Todos los eventos atómicos son exhaustivos (alguno debe ocurrir)
  - Un evento atómico implica la verdad o falsedad de toda proposición
  - Toda proposición es equivalente a la disyunción de un conjunto de eventos atómicos: por ejemplo, *caries* es equivalente a  $(\text{caries} \wedge \text{dolor}) \vee (\text{caries} \wedge \neg \text{dolor})$

# Probabilidad incondicional

- Probabilidad *incondicional* (o *a priori*) asociada a una proposición  $a$ :
  - Grado de creencia sobre  $a$ , en ausencia de cualquier otra información o evidencia, notada  $P(a)$
  - Ejemplo:  $P(\text{caries}) = 0,1$ ,  $P(\text{caries} \wedge \neg \text{dolor}) = 0,05$
  - Notación:  $P(\text{caries}, \neg \text{dolor})$  es equivalente a  $P(\text{caries} \wedge \neg \text{dolor})$
- *Distribución de probabilidad* de una variable aleatoria
  - Ejemplo: *Tiempo* es una v.a. con valores *lluvia*, *sol*, *nubes* y *nieve*; una distribución de probabilidad viene dada por las probabilidades de que la variable pueda tomar los diferentes valores
  - $P(\text{Tiempo} = \text{sol}) = 0,7$ ,  $P(\text{Tiempo} = \text{lluvia}) = 0,2$ ,  $P(\text{Tiempo} = \text{nubes}) = 0,08$ ,  $P(\text{Tiempo} = \text{nieve}) = 0,02$

# Probabilidad incondicional

- Notación: usaremos  $P$  (en negrita), para expresar de manera compacta una distribución de probabilidad (fijado un orden entre sus valores)
  - Ejemplo:  $P(Tiempo) = \langle 0,7, 0,2, 0,08, 0,02 \rangle$
- Distribución de probabilidad *conjunta*: probabilidad de cada combinación de valores de dos o más variables aleatorias
  - Notación  $P(X, Y)$ : manera compacta de denotar a una tabla con esas probabilidades
  - $P(Tiempo, Caries)$  denota una tabla con  $4 \times 2$  entradas
  - Distribución de probabilidad *conjunta y completa* (DCC): probabilidad de cada evento atómico
  - Una DCC es una *especificación completa* de la incertidumbre que se tiene sobre el “mundo” descrito

# Probabilidad condicional

- Probabilidad *condicional* (o *a posteriori*) asociada a  $a$  dada  $b$  ( $a$  y  $b$  proposiciones):
  - Grado de creencia sobre  $a$ , dado que *todo lo que sabemos* es que  $b$  ocurre, notada  $P(a|b)$
  - Ejemplo:  $P(\text{caries}|\text{dolor}) = 0,8$  significa que una vez sabido que un paciente tiene dolor de muelas (y sólo sabemos eso), nuestra creencia es que el paciente tendrá caries con probabilidad 0,8
- Relación entre probabilidad condicional e incondicional:
  - $P(a|b) = \frac{P(a \wedge b)}{P(b)}$ , o también
  - $P(a \wedge b) = P(a|b)P(b)$  (regla del producto)
- Notación  $P(X|Y)$  para expresar la tabla de probabilidades condicionales
  - Forma compacta de la regla del producto:  $P(X, Y) = P(X|Y)P(Y)$



## Probabilidad condicional *vs* implicación lógica

- La probabilidad condicional formaliza el hecho de que los grados de creencias se actualizan a medida que se van conociendo nuevas evidencias en el mundo incierto
- La probabilidad condicional *no* es lo mismo que una implicación lógica con incertidumbre
  - $P(a|b) = 0,8$  no es lo mismo que decir que “siempre que  $b$  sea verdad, entonces  $P(a) = 0,8$ ”
  - Ya que  $P(a|b)$  refleja que  $b$  es *la única* evidencia conocida

# Axiomas de probabilidad y cálculo

- Interpretación de la función  $P$ 
  - Frecuentista: casos posibles entre casos totales
  - Subjetiva: grado de creencia basado en nuestras percepciones
- Axiomas sobre la función de probabilidad
  - $0 \leq P(a) \leq 1$
  - $P(true) = 1$  y  $P(false) = 0$  donde  $true$  y  $false$  representan a cualquier proposición tautológica o insatisfactible, respectivamente
  - $P(a \vee b) = P(a) + P(b) - P(a \wedge b)$
- El resto del cálculo de probabilidades se construye sobre estos tres axiomas. Por ejemplo:
  - $P(\neg a) = 1 - P(a)$
  - $\sum_{i=1}^n P(D = d_i) = 1$ , siendo  $D$  una v.a. y  $d_i, i = 1, \dots, n$  sus posibles valores
  - $P(a) = \sum_{e_i \in e(a)} P(e_i)$ , siendo  $a$  una proposición y  $e(a)$  el conjunto de eventos atómicos cuya disyunción es equivalente a  $a$

# Inferencia probabilística

- Por *inferencia probabilística* entendemos el cálculo de la probabilidad de una proposición dada *condicionada* por la observación de determinadas evidencias
  - Es decir, cálculos del tipo  $P(a|b)$  donde  $a$  es la proposición que se *consulta* y  $b$  es la proposición que se ha *observado*
  - El *conocimiento base* vendrá dado por una DCC (representada de alguna manera *eficiente*, como ya veremos)
- Ejemplo de DCC:

	<i>dolor</i>	<i>dolor</i>	$\neg$ <i>dolor</i>	$\neg$ <i>dolor</i>
	<i>hueco</i>	$\neg$ <i>hueco</i>	<i>hueco</i>	$\neg$ <i>hueco</i>
<i>caries</i>	0.108	0.012	0.072	0.008
$\neg$ <i>caries</i>	0.016	0.064	0.144	0.576

## Inferencia probabilística a partir de una DCC

- Cálculo de probabilidades incondicionales basado en la ecuación  $P(a) = \sum_{e_i \in \mathbf{e}(a)} P(e_i)$ 
  - $P(\text{caries} \vee \text{dolor}) = 0,108 + 0,012 + 0,072 + 0,008 + 0,016 + 0,064 = 0,28$
  - $P(\text{caries}) = 0,108 + 0,012 + 0,072 + 0,008 = 0,2$
- En general:
  - $P(Y) = \sum_z P(Y, z)$  (regla de marginalización)
- Notación:
  - $Y$  es un vector de variables aleatorias, simbolizando cualquier combinación de valores de esas variables
  - $z$  representa una combinación de valores concretos para un conjunto  $Z$  de variables aleatorias (las restantes)
- Variante:  $P(Y) = \sum_z P(Y|z) \cdot P(z)$  (regla de condicionantes)

## Inferencia probabilística a partir de una DCC

- Cálculo de probabilidades condicionales usando la DCC (un ejemplo)

- Probabilidad de tener caries, observado que hay dolor:

$$P(\text{caries}|\text{dolor}) = \frac{P(\text{caries} \wedge \text{dolor})}{P(\text{dolor})} = \frac{0,108 + 0,012}{0,108 + 0,012 + 0,016 + 0,064} = 0,6$$

- Como comprobación podemos calcular el opuesto:

$$P(\neg \text{caries}|\text{dolor}) = \frac{P(\neg \text{caries} \wedge \text{dolor})}{P(\text{dolor})} = \frac{0,016 + 0,064}{0,108 + 0,012 + 0,016 + 0,064} = 0,4$$

- $P(\text{dolor})$  puede verse como una constante que *normaliza* la distribución  $P(\text{Caries}|\text{dolor})$  haciendo que sume 1:

$$\begin{aligned} P(\text{Caries}|\text{dolor}) &= \alpha P(\text{Caries}, \text{dolor}) = \\ &= \alpha [P(\text{Caries}, \text{dolor}, \text{hueco}) + P(\text{Caries}, \text{dolor}, \neg \text{hueco})] = \\ &= \alpha [\langle 0,108, 0,016 \rangle + \langle 0,012, 0,064 \rangle] = \alpha \langle 0,12, 0,08 \rangle = \langle 0,6, 0,4 \rangle \end{aligned}$$

## Inferencia probabilística a partir de una DCC

- En general, dada una variable aleatoria  $X$ , un conjunto de variables observadas  $E$  (con valor concreto  $e$ ), se tiene:

$$P(X|e) = \alpha P(X, e) = \alpha \sum_y P(X, e, y)$$

- un sumando para cada combinación  $y$  de valores de las variables restantes  $Y$  no observadas
- $\alpha$  es una constante de normalización, que hace que la distribución de probabilidades sume 1
- Dada una DCC, la fórmula anterior nos da un método para realizar inferencia probabilística
- Problema en la práctica: exponencialidad
  - Con  $n$  variables, procesar la DCC necesita un tiempo  $O(2^n)$
  - En un problema real, podría haber cientos o miles de variables

# Independencia probabilística

- En muchos casos prácticos, muchas de las variables de un problema son *independientes* entre sí
  - Ejemplo:  $P(\text{Tiempo} = \text{nublado} | \text{dolor}, \text{caries}, \text{hueco}) = P(\text{Tiempo} = \text{nublado})$
  - Si la variable *Tiempo* (con 4 posibles valores) formara parte de una descripción en la que están *Caries*, *Hueco* y *Dolor*, no necesitaríamos una tabla con 32 entradas para describir la DCC, sino dos tablas independientes (8+4 entradas)
- Dos variables aleatorias  $X$  e  $Y$  son independientes si  $P(X|Y) = P(X)$  (equivalentemente,  $P(Y|X) = P(Y)$  ó  $P(X, Y) = P(X) \cdot P(Y)$ )
  - En general, dos proposiciones  $a$  y  $b$  son independientes si  $P(a|b) = P(a)$
- Asumir independencia entre ciertas variables ayuda a que la representación del mundo sea más manejable
  - Reduce la exponencialidad (*factorización* del problema)
  - El asumir que dos variables son independientes está basado normalmente el en conocimiento previo del dominio que se modela

## La regla de Bayes

- De  $P(a \wedge b) = P(a|b)P(b) = P(b|a)P(a)$  podemos deducir la siguiente fórmula, conocida como *regla de Bayes*:

$$P(b|a) = \frac{P(a|b)P(b)}{P(a)}$$

- Regla de Bayes para variables aleatorias:

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

- recuérdese que esta notación representa un conjunto de ecuaciones, una para cada valor específico de las variables
- Generalización, en presencia de un conjunto  $e$  de observaciones:

$$P(Y|X, e) = \frac{P(X|Y, e)P(Y|e)}{P(X|e)}$$



## Uso de la regla de Bayes

- La regla de Bayes nos permite *diagnosticar* en función de nuestro conocimiento de relaciones *causales*
- Ejemplo
  - Sabemos que la probabilidad de que un paciente de meningitis tenga el cuello hinchado es 0.5 (relación causal)
  - También sabemos la probabilidad (incondicional) de tener meningitis ( $\frac{1}{50000}$ ) y de tener el cuello hinchado (0.05)
  - Estas probabilidades provienen del conocimiento y la experiencia
  - La regla de Bayes nos permite diagnosticar la probabilidad de tener meningitis una vez que se ha observado que el paciente tiene el cuello hinchado:

$$P(m|h) = \frac{P(h|m)P(m)}{P(h)} = \frac{0,5 \times \frac{1}{50000}}{0,05} = 0,0002$$

## Uso de la regla de Bayes

- Una variante del ejemplo anterior:
  - Si  $M$  es una variable aleatoria booleana, podríamos calcular con la siguiente fórmula, donde  $\alpha$  es el factor de normalización:
$$P(M|h) = \alpha \langle P(h|m)P(m), P(h|\neg m)P(\neg m) \rangle$$
- Versión para variables aleatorias:  $P(Y|X) = \alpha P(X|Y)P(Y)$
- ¿Por qué calcular el diagnóstico en función del conocimiento causal y no al revés?
  - Porque es más fácil y robusto disponer de probabilidades causales que de probabilidades de diagnóstico
  - La información probabilística está generalmente disponible en la forma  $P(efecto|causa)$
  - Y usamos la regla de Bayes para calcular  $P(causa|efecto)$

# La regla de Bayes: combinando evidencias

- Evidencias múltiples y exponencialidad
  - Cuando manejamos varias variables para representar distintas evidencias (y es lo habitual), el uso de la regla de Bayes puede necesitar una cantidad exponencial de probabilidades de tipo  $P(\text{efecto}|\text{causa})$
  - Supongamos, por ejemplo, que tenemos evidencias sobre oquedades en los dientes (*Hueco*) y sobre dolor en el paciente (*Dolor*), y queremos diagnosticar si tiene caries (*Caries*)
  - Por la regla de Bayes:  $P(\text{Caries}|\text{Dolor}, \text{Hueco}) = \alpha P(\text{Dolor}, \text{Hueco}|\text{Caries})P(\text{Caries})$
  - En general, si se tienen  $n$  variables booleanas de evidencia, deberíamos tener  $2^n$  probabilidades condicionales (por cada valor de una variable de diagnóstico) en nuestra base de conocimiento
  - Esta exponencialidad no se maneja bien desde el punto de vista práctico
- Nuevamente, asumir cierta noción de *independencia* entre variables simplificará la cuestión

## Independencia condicional

- Sin embargo, en nuestro ejemplo *Dolor* y *Hueco* no son independientes
  - Ambas dependen de *Caries*
- Pero son independientes *una vez conocido el valor de Caries*
  - Es decir:  $P(Dolor|Hueco, Caries) = P(Dolor|Caries)$  o equivalentemente  $P(Hueco|Dolor, Caries) = P(Hueco|Caries)$
  - También equivalente:  $P(Hueco, Dolor|Caries) = P(Hueco|Caries)P(Dolor|Caries)$
- En general, dos v.a.  $X$  e  $Y$  son independientes dada una v.a.  $Z$  si  $P(X, Y|Z) = P(X|Z)P(Y|Z)$ 
  - O equivalentemente  $P(X|Y, Z) = P(X|Z)$  ó  $P(Y|X, Z) = P(Y|Z)$
- Esto simplifica la inferencia probabilística:
$$\underline{P(Caries|Dolor, Hueco) = \alpha P(Dolor|Caries)P(Hueco|Caries)P(Caries)}$$
  - Sólo es necesario saber las probabilidades causales de cada variable *por separado*
  - “Reduciendo” la exponencialidad

# Independencia condicional

- La independencia condicional entre algunas variables es esencial para un almacenamiento eficiente de las DCCs. Por ejemplo:

$$\begin{aligned} P(\text{Dolor}, \text{Hueco}, \text{Caries}) &= P(\text{Dolor}, \text{Hueco} | \text{Caries}) P(\text{Caries}) = \\ &= P(\text{Dolor} | \text{Caries}) P(\text{Hueco} | \text{Caries}) P(\text{Caries}) \end{aligned}$$

- En lugar de tener una tabla con 7 números independientes sólo necesitamos 5 números independientes (en tres tablas)
- Si *Caries* tuviera  $n$  síntomas independientes entre sí (dado *Caries*), el tamaño de la representación de la DCC crece  $O(n)$  en lugar de  $O(2^n)$
- Con una *Causa* con  $n$  efectos  $E_i$  independientes entre sí dado *Causa*, se tiene  $P(\text{Causa}, E_1, \dots, E_n) = P(\text{Causa}) \prod_i P(E_i | \text{Causa})$ 
  - No siempre se dan estas condiciones de independencia tan fuertes, aunque a veces compensa asumirlas

## Ejemplo

- Problema
  - Un 1 % de las mujeres de más de 40 años que se hacen un chequeo tienen cancer de mama. Un 80 % de las que tienen cancer de mama se detectan con una mamografía y el 9.6 % de las que no tienen cancer de mama, al realizarse una mamografía se le diagnostica cáncer erróneamente
- Variables aleatorias:  $C$  (tener cancer de mama) y  $M$  (mamografía positiva)
- Pregunta 1: ¿cuál es la probabilidad de tener cancer si la mamografía así lo diagnostica?
  - $P(C|m) = \alpha P(C, m) = \alpha P(m|C)P(C) = \alpha \langle P(m|c)P(c), P(m|\neg c)P(\neg c) \rangle = \alpha \langle 0,8 \cdot 0,01, 0,096 \cdot 0,99 \rangle = \alpha \langle 0,008, 0,09504 \rangle = \langle 0,0776, 0,9223 \rangle$
  - Luego el 7.8 % de las mujeres diagnosticadas positivamente con mamografía tendrán realmente cancer de mama

## Ejemplo

- Pregunta 2: ¿cuál es la probabilidad de tener cancer si tras dos mamografías consecutivas en ambas se diagnostica cancer?
  - Variables aleatorias:  $M_1$  (primera mamografía positiva) y  $M_2$  (segunda mamografía positiva)
  - Obviamente, no podemos asumir independencia incondicional entre  $M_1$  y  $M_2$
  - Pero es plausible asumir independencia condicional de  $M_1$  y  $M_2$  *dada*  $C$
  - Por tanto, 
$$P(C|m_1, m_2) = \alpha P(C, m_1, m_2) = \alpha P(m_1, m_2|C)P(C) = \alpha P(m_1|C)P(m_2|C)P(C) = \alpha \langle P(m_1|c)P(m_2|c)P(c), P(m_2|\neg c)P(m_2|\neg c)P(\neg c) \rangle = \alpha \langle 0,8 \cdot 0,8 \cdot 0,01, 0,096 \cdot 0,096 \cdot 0,99 \rangle = \langle 0,412, 0,588 \rangle$$
  - Luego aproximadamente el 41 % de las mujeres doblemente diagnosticadas positivamente con mamografía tendrán realmente cancer de mama

# Redes Bayesianas

- En general, las relaciones de independencia condicional permiten simplificar drásticamente las DCCs, haciendo que se puedan usar en la práctica
- Las Redes Bayesianas constituyen un método de representación de DCCs que explota las relaciones de independencia condicional
  - Permitiendo un tratamiento manejable de la inferencia probabilística
  - Es lo que veremos en el próximo tema



## Bibliografía

- Russell, S. y Norvig, P. *Inteligencia artificial (Un enfoque moderno)* (Prentice–Hall Hispanoamericana, 1996)
  - Cap. 13: “Incertidumbre”